Rapport de Projet

WeatherScope

Big Data and NoSQL

Réalisé par
DITER Justin & SANCHEZ Louise

Encadré par
Mme. AKID-ZEKRI Hajer

Master 2 Informatique Parcours Systèmes Logiciels et Calculs Distribués
Université Côte d'Azur - Année 2026-2027

Résumé

Ce rapport présente ....

Abstract

This report studies .....

Table des matières

1 Introduction **4**

2 Périmètre Géographique, Temporalité & Provenance des Données **4**
2.1 Périmètre d'étude 4
2.2 Traçabilité, Traitement des Drapeaux (Flags) et Valeurs Manquantes 5

3 Architecture Système & Implémentation des Services **6**

4 Conclusion **6**

A Anomalies relevées dans les données **7**

1 Introduction

WeatherScope est un prototype d'analyse de données météo historiques, commandé par un observatoire régional. Il permet de choisir une zone et une période, de repérer des épisodes inhabituels (chaleur, fortes pluies), de comparer des zones, et de remonter à chaque fois jusqu'aux observations sources. Il tourne d'abord sur un seul serveur MongoDB, puis sur un cluster shardé.

Comme cas d'usage, nous avons choisi les hivers. L'un de nous a grandi près de Détroit et a l'impression qu'il y neige moins qu'avant, et que la neige tient moins longtemps au sol. Nous voulons voir si les données vont dans ce sens, et comparer avec le sud de l'Allemagne : même bande de latitude, mais un climat différent (air arctique et neige d'effet de lac au Michigan, air atlantique plus doux en Allemagne). D'où notre question : *entre 1991 et 2020, les hivers ont-ils changé de la même façon dans les deux zones ?*

Nous suivons trois indicateurs : le nombre de jours avec de la neige au sol (SNWD > 0), les dates du premier et du dernier jour d'enneigement, et le nombre de jours de gel (TMIN $<$ 0 °C). Les services de WeatherScope couvrent toute l'année ; l'hiver nous sert d'exemple.

2 Périmètre Géographique, Temporalité & Provenance des Données

2.1 Périmètre d'étude

Données. Toutes les observations viennent de GHCN-Daily, l'archive quotidienne de la NOAA [1]. Les métadonnées ont été récupérées le 8 novembre 2026 ; l'URL, la date et le SHA-256 de chaque fichier sont dans `data/raw/metadata/MANIFEST.json`. La sélection se refait avec `scripts/select_stations.py`.

Zones. Le Michigan regroupe les stations américaines avec le code d'État `MI`. Le sud de l'Allemagne regroupe les stations situées en Bavière ou en Bade-Wurtemberg, d'après les frontières de Natural Earth [5]. Les deux zones ont une surface proche (environ 146 000 et 106 000 km^2). Nous écartons les stations allemandes au-dessus de 800 m (18 stations, dans les Alpes et la Forêt-Noire), car la neige y dépend surtout de l'altitude ; le Michigan ne dépasse pas 523 m. Les latitudes ne sont pas identiques : la moitié des stations du Michigan sont au sud de 43,0°N, la moitié des allemandes au nord de 48,8°N (figure 1).

Période. Nous étudions 1991–2020, la normale climatique actuelle de l'OMM [2]. La référence pour les anomalies (F3) est 1961–1990 ; elle passe par le même chargement mais est comptée à part. Un hiver va de décembre à février : 30 hivers, de 1990–91 à 2019–20.

Stations. Nous gardons les stations qui ont des données TMAX, TMIN ou PRCP sur 1991–2020 (tableau 1). Les réseaux diffèrent : au Michigan, 675 stations viennent de CoCoRaHS, un réseau de bénévoles [3], et la plupart n'existent que depuis 2005. En Allemagne, le réseau (ECA&D [4]) reste stable. Une moyenne sur toutes les stations montrerait donc surtout l'arrivée de nouvelles stations. Pour les tendances, nous n'utilisons que les 233 stations

« à longue série » : celles qui ont au moins 80 % de mois valides sur 1991–2020 pour TMAX, TMIN ou PRCP, un mois étant valide s'il lui manque au plus 5 jours, dont au plus 3 consécutifs (règle 3/5 de l'OMM [2]). L'inventaire de la NOAA en annonçait 269, mais il ne donne que la première et la dernière année et masque les trous (annexe A). Une fois chargées, les données comptent 5,1 millions de couples station–jour sur 1991–2020 (3,4 millions sur la référence), pour 200 000 demandés.

La hauteur de neige (SNWD) est disponible dans les deux zones. Les chutes de neige (SNOW) n'existent qu'au Michigan.

	Michigan	Sud de l'Allemagne
Stations de la zone	1 560	400
Stations retenues	1 058	295
dont à longue série (mesurée)	94	139
dont débutées en 2005 ou après	763	18
Stations retenues par élément : avec données / sur toute la période		
TMAX	317 / 95	264 / 93
TMIN	319 / 98	264 / 94
PRCP	1 045 / 117	294 / 148
SNOW	1 009 / 109	–
SNWD	890 / 110	287 / 140

Tableau 1: Stations retenues sur 1991–2020 (inventaire NOAA du 8/11/2026).

2.2 Traçabilité, Traitement des Drapeaux (Flags) et Valeurs Manquantes

Traçabilité. Chaque observation garde sa valeur brute, ses trois drapeaux, son heure d'observation, le fichier source et le lot d'import qui l'a écrite. Son identifiant est `station:date:élément` : pour tout résultat, on peut lister les relevés qui l'ont produit. Un import ne crée jamais de doublon : une valeur identique est ignorée, une valeur modifiée remplace l'ancienne, qui est conservée dans un historique. Chaque lot enregistre ses fichiers et leur SHA-256.

Drapeaux. Rien n'est supprimé au chargement ; les règles s'appliquent dans les requêtes. Une valeur avec un drapeau qualité (0,18 % des observations) est exclue des analyses. Le drapeau `P` (« manquant, présumé nul », 1,5 million de valeurs au Michigan) est traité comme une donnée manquante, pas comme un zéro. Une trace (`T`) compte comme un jour de précipitation de quantité négligeable. Les contrôles de la NOAA suffisent : nous n'avons trouvé aucune valeur aberrante ni aucun TMAX inférieur à TMIN sans drapeau (annexe A).

Valeurs manquantes. Nous ne comblons aucun trou. Un mois qui ne respecte pas la règle 3/5 n'entre pas dans les anomalies mensuelles (F3), et un jour manquant ou signalé interrompt un épisode (F2). Deux identifiants à moins d'un kilomètre l'un de l'autre (95 paires) comptent pour un seul site dans F3 et F4.

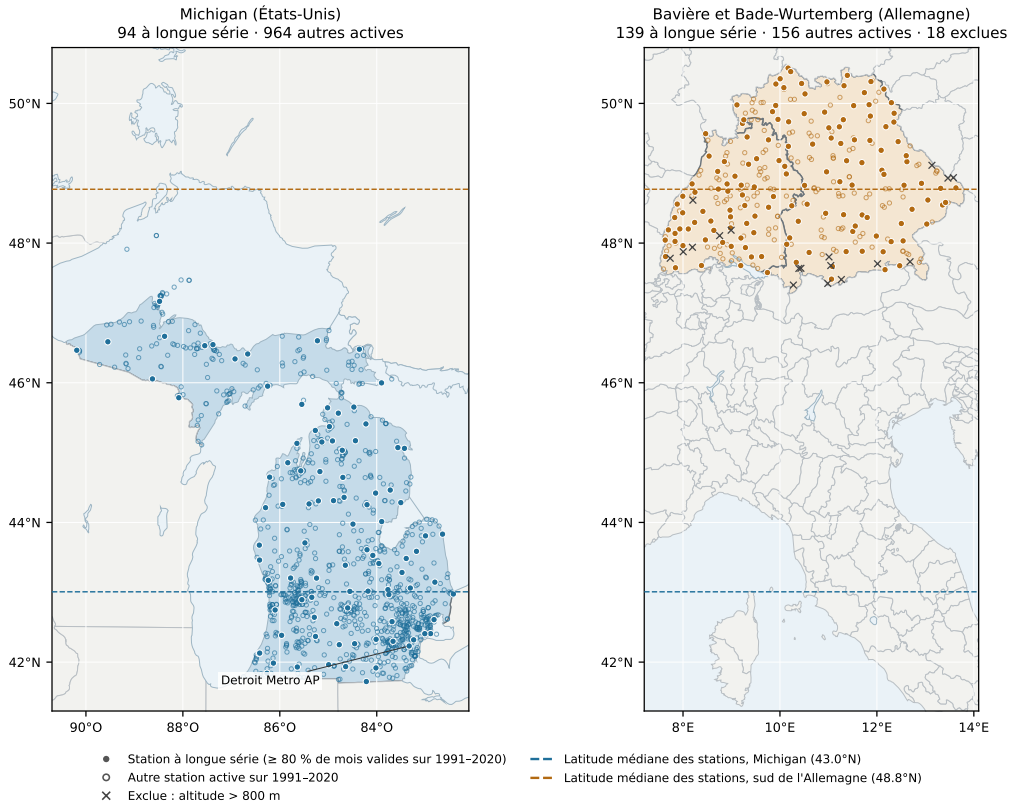


Figure 1: Stations retenues, à la même échelle. Pointillés : latitude médiane des stations de chaque zone.

Heure d'observation. En Allemagne, ECA&D ne donne pas d'heure : chaque valeur couvre le jour climatologique du service météo national. Au Michigan, sur les 315 stations qui mesurent TMAX entre 1991 et 2020, 203 relèvent le matin (surtout à 7 h ou 8 h), 42 l'après-midi ou le soir, 28 à minuit (aéroports) et 42 ne donnent pas d'heure ; 118 ont changé d'heure au moins une fois. Pour une station relevée à 8 h, la TMAX notée le jour J est en général celle de l'après-midi de la veille. Deux stations voisines peuvent donc dater le même épisode avec un jour d'écart. F4 tolère ce décalage d'un jour entre stations, et les deux zones (UTC−5 et UTC+1) sont comparées sur des valeurs mensuelles ou saisonnières, jamais jour par jour.

3 Architecture Système & Implémentation des Services

4 Conclusion

Dans ce Projet ...

Références

[1] M. J. Menne, I. Durre, R. S. Vose, B. E. Gleason et T. G. Houston. An overview of the Global Historical Climatology Network-Daily database. *Journal of Atmospheric and Oceanic Technology*, 29(7):897–910, 2012.

[2] World Meteorological Organization. *WMO Guidelines on the Calculation of Climate Normals*. WMO-No. 1203, Genève, 2017.

[3] R. Cifelli, N. Doesken, P. Kennedy, L. D. Carey, S. A. Rutledge, C. Gimmestad et T. Depue. The Community Collaborative Rain, Hail, and Snow Network: informal education for scientists and citizens. *Bulletin of the American Meteorological Society*, 86(8):1069–1077, 2005.

[4] A. M. G. Klein Tank et al. Daily dataset of 20th-century surface air temperature and precipitation series for the European Climate Assessment. *International Journal of Climatology*, 22(12):1441–1453, 2002.

[5] Natural Earth. 1:10m Cultural Vectors, Admin 1 – States, Provinces; 1:10m Physical Vectors, Lakes. Version 5.1.2. `https://www.naturalearthdata.com`, domaine public.

A Anomalies relevées dans les données

Les fréquences portent sur les 31,6 millions d'observations chargées (1961–2020, 1 352 stations). Les exemples sont des lignes réelles des fichiers `by_station` de la NOAA, au format `station,date,élément,valeur,M,Q,S,heure` ; elles ont été relues dans les fichiers d'origine. Comptages produits par `scripts/coverage_report.py` (`results/coverage/anomalies.json`).

A1. Valeurs signalées par un drapeau qualité. 56 360 valeurs (0,18 %) portent un drapeau qualité, dont 47 431 le drapeau `I` (échec d'un contrôle de cohérence interne, par exemple TMAX inférieur à TMIN). Le Michigan en concentre la grande majorité.
`GM000002698,19620128,TMIN,4,,I,E,` (Karlsruhe, 0,4 °C signalé `I`).
Traitement : valeur conservée et traçable, exclue des analyses.

A2. Valeurs physiquement impossibles. 63 valeurs portent le drapeau `X` (hors limites) et 255 le drapeau `G` (valeur aberrante). Le cas le plus net est Big Rapids (Michigan) le 11 janvier 1982 : 2 032 mm de pluie, 2 606 mm de neige et 38,9 °C le même jour d'hiver.

```
USC00200779,19820111,PRCP,20323,,X,0,2400
USC00200779,19820111,SNOW,2606,,X,0,
USC00200779,19820111,TMAX,389,,G,0,2400
```

Nous n'avons trouvé aucune valeur hors de nos bornes de plausibilité sans drapeau NOAA.
Traitement : comme A1.

A3. Précipitations « manquantes, présumées nulles » (drapeau P). 1 466 628 valeurs PRCP ou SNOW portent le drapeau de mesure `P`, sur 298 stations, toutes au Michigan (aucune en Allemagne).
`USC00200032,19820105,PRCP,0,P,,0,2400` (Adrian, Michigan).
Traitement : traitées comme manquantes, jamais comme un vrai zéro. Les traces (`T`, valeur 0) sont comptées comme jour de précipitation de quantité négligeable.

A4. Neige au sol en été, sans drapeau. 4 valeurs de hauteur de neige positives en juin, juillet ou août, toutes les 1er et 2 juin 1962, à quatre stations allemandes différentes (10 à 90 mm).
`GME00102412,19620602,SNWD,40,,E,` (Kempten, 40 mm).
Traitement : conservées. Plusieurs stations voisines les mêmes jours évoquent plutôt une vraie chute de neige tardive qu'une erreur : c'est le cas qu'un événement régional (F4) doit distinguer d'un extrême isolé.

A5. Un même site sous deux identifiants. 95 paires de stations sont à moins de 1 km l'une de l'autre. À Gelbelsee (Bavière), `GMM00010777` (1988–2003) et `GME00122734` (depuis 1998) sont à 250 m. Sur les 36 jours de 2003 où les deux donnent TMAX, 33 valeurs sont identiques et 3 diffèrent.
`GMM00010777,20030518,TMAX,158,,S,` `GME00122734,20030518,TMAX,158,,E,`
`GMM00010777,20030525,TMAX,181,,S,` `GME00122734,20030525,TMAX,215,,E,`
Traitement : stations gardées séparément ; dans F3 et F4, une paire ne compte que pour un seul site.

A6. Séries qui commencent, s'arrêtent ou s'interrompent. Au Michigan, 888 stations commencent après janvier 1991 et 609 s'arrêtent avant décembre 2020 (67 et 108 en Allemagne). Parmi les stations à longue série, la plus longue interruption est à Tirschenreuth-Lodermühl : 1 947 jours sans donnée.
`GME00129298,20021031,TMAX,60,,E,` puis `GME00129298,20080301,TMAX,85,,E,`
L'inventaire peut masquer ces trous : il annonce TMIN de 1943 à 2026 pour Michigamme (`USC00205403`), alors que le fichier s'arrête en 1949 et ne reprend qu'en 2022.
Traitement : statut « longue série » mesuré mois par mois (règle 3/5 de l'OMM), pas d'après l'inventaire.