Rapport de Projet

WeatherScope

Big Data and NoSQL

Réalisé par
DITER Justin & SANCHEZ Louise

Encadré par
Mme. AKID-ZEKRI Hajer

Master 2 Informatique Parcours Systèmes Logiciels et Calculs Distribués
Université Côte d'Azur - Année 2026-2027

Résumé

Ce rapport présente ....

Abstract

This report studies .....

Table des matières

1 Introduction **4**

2 Périmètre Géographique, Temporalité & Provenance des Données **4**
2.1 Périmètre d'étude 4
2.2 Traçabilité, Traitement des Drapeaux (Flags) et Valeurs Manquantes 6

3 Architecture Système & Implémentation des Services **6**

4 Conclusion **6**

1 Introduction

WeatherScope est un prototype d'analyse de données météo historiques, commandé par un observatoire régional. Il permet de choisir une zone et une période, de repérer des épisodes inhabituels (chaleur, fortes pluies), de comparer des zones, et de remonter à chaque fois jusqu'aux observations sources. Il tourne d'abord sur un seul serveur MongoDB, puis sur un cluster shardé.

Comme cas d'usage, nous avons choisi les hivers. L'un de nous a grandi près de Détroit et a l'impression qu'il y neige moins qu'avant, et que la neige tient moins longtemps au sol. Nous voulons voir si les données vont dans ce sens, et comparer avec le sud de l'Allemagne : même bande de latitude, mais un climat différent (air arctique et neige d'effet de lac au Michigan, air atlantique plus doux en Allemagne). D'où notre question : *entre 1991 et 2020, les hivers ont-ils changé de la même façon dans les deux zones ?*

Nous suivons trois indicateurs : le nombre de jours avec de la neige au sol (SNWD > 0), les dates du premier et du dernier jour d'enneigement, et le nombre de jours de gel (TMIN $<$ 0 °C). Les services de WeatherScope couvrent toute l'année ; l'hiver nous sert d'exemple.

2 Périmètre Géographique, Temporalité & Provenance des Données

2.1 Périmètre d'étude

Données. Toutes les observations viennent de GHCN-Daily, l'archive quotidienne de la NOAA [1]. Les métadonnées ont été récupérées le 8 novembre 2026 ; l'URL, la date et le SHA-256 de chaque fichier sont dans `data/raw/metadata/MANIFEST.json`. La sélection se refait avec `scripts/select_stations.py`.

Zones. Le Michigan regroupe les stations américaines avec le code d'État `MI`. Le sud de l'Allemagne regroupe les stations situées en Bavière ou en Bade-Wurtemberg, d'après les frontières de Natural Earth [5]. Les deux zones ont une surface proche (environ 146 000 et 106 000 km^2). Nous écartons les stations allemandes au-dessus de 800 m (18 stations, dans les Alpes et la Forêt-Noire), car la neige y dépend surtout de l'altitude ; le Michigan ne dépasse pas 523 m. Les latitudes ne sont pas identiques : la moitié des stations du Michigan sont au sud de 43,0°N, la moitié des allemandes au nord de 48,8°N (figure 1).

Période. Nous étudions 1991–2020, la normale climatique actuelle de l'OMM [2]. La référence pour les anomalies (F3) est 1961–1990 ; elle passe par le même chargement mais est comptée à part. Un hiver va de décembre à février : 30 hivers, de 1990–91 à 2019–20.

Stations. Nous gardons les stations qui ont des données TMAX, TMIN ou PRCP sur 1991–2020 (tableau 1). Les réseaux diffèrent : au Michigan, 675 stations viennent de CoCoRaHS, un réseau de bénévoles [3], et la plupart n'existent que depuis 2005. En Allemagne, le réseau (ECA&D [4]) reste stable. Une moyenne sur toutes les stations montrerait donc surtout l'arrivée de nouvelles stations. Pour les tendances, nous n'utilisons que les 269 stations « à

longue série », qui couvrent toute la période. Elles suffisent pour les minimums du sujet : plus de 100 stations, et au plus 2,9 millions de couples station–jour pour 200 000 demandés. L'inventaire ne donne que la première et la dernière année : les trous seront vérifiés après chargement.

La hauteur de neige (SNWD) est disponible dans les deux zones. Les chutes de neige (SNOW) n'existent qu'au Michigan.

	Michigan	Sud de l'Allemagne
Stations de la zone	1 560	400
Stations retenues	1 058	295
dont à longue série	119	150
dont débutées en 2005 ou après	763	18
Stations retenues par élément : avec données / sur toute la période		
TMAX	317 / 95	264 / 93
TMIN	319 / 98	264 / 94
PRCP	1 045 / 117	294 / 148
SNOW	1 009 / 109	–
SNWD	890 / 110	287 / 140

Tableau 1: Stations retenues sur 1991–2020 (inventaire NOAA du 8/11/2026).

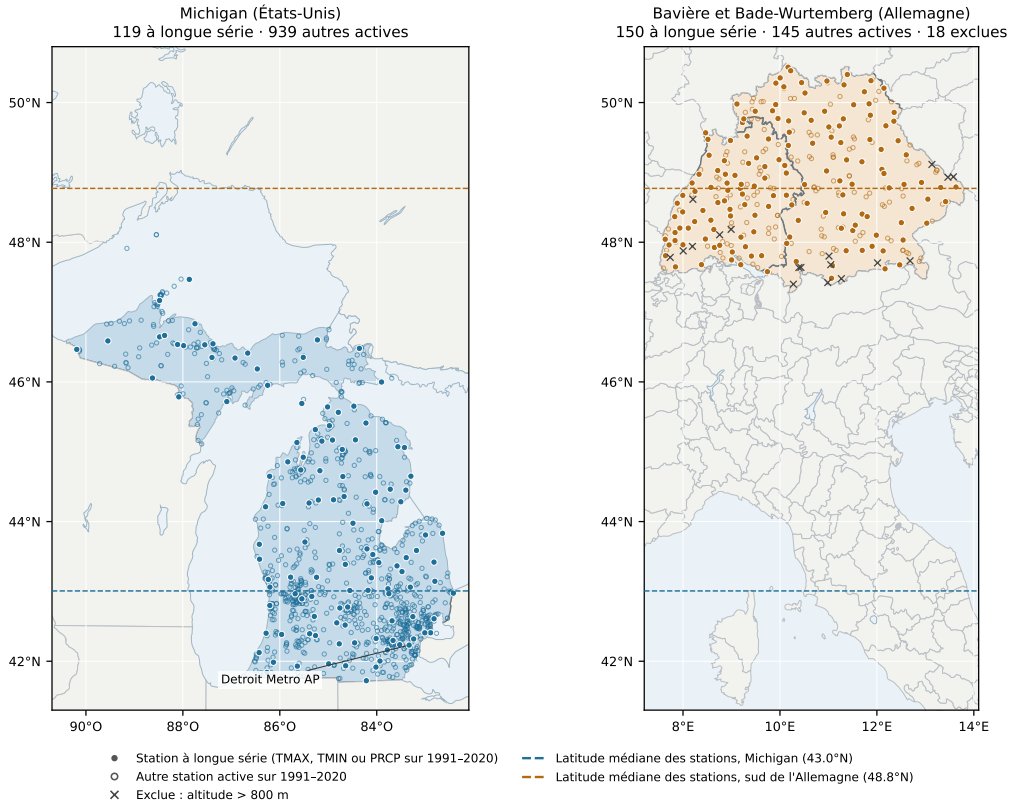


Figure 1: Stations retenues, à la même échelle. Pointillés : latitude médiane des stations de chaque zone.

2.2 Traçabilité, Traitement des Drapeaux (Flags) et Valeurs Manquantes

3 Architecture Système & Implémentation des Services

4 Conclusion

Dans ce Projet ...

Références

[1] M. J. Menne, I. Durre, R. S. Vose, B. E. Gleason et T. G. Houston. An overview of the Global Historical Climatology Network-Daily database. *Journal of Atmospheric and Oceanic Technology*, 29(7):897–910, 2012.

[2] World Meteorological Organization. *WMO Guidelines on the Calculation of Climate Normals*. WMO-No. 1203, Genève, 2017.

[3] R. Cifelli, N. Doesken, P. Kennedy, L. D. Carey, S. A. Rutledge, C. Gimmestad et T. Depue. The Community Collaborative Rain, Hail, and Snow Network: informal education for scientists and citizens. *Bulletin of the American Meteorological Society*, 86(8):1069–1077, 2005.

[4] A. M. G. Klein Tank et al. Daily dataset of 20th-century surface air temperature and precipitation series for the European Climate Assessment. *International Journal of Climatology*, 22(12):1441–1453, 2002.

[5] Natural Earth. 1:10m Cultural Vectors, Admin 1 – States, Provinces; 1:10m Physical Vectors, Lakes. Version 5.1.2. `https://www.naturalearthdata.com`, domaine public.