Rapport de Projet

WeatherScope

Big Data and NoSQL

Réalisé par
DITER Justin & SANCHEZ Louise

Encadré par
Mme. AKID-ZEKRI Hajer

Master 2 Informatique Parcours Systèmes Logiciels et Calculs Distribués
Université Côte d'Azur - Année 2026-2027

1 Introduction

WeatherScope est un prototype d'analyse de données météo historiques, commandé par un observatoire régional. Il permet de choisir une zone et une période, de repérer des épisodes inhabituels (chaleur, fortes pluies), de comparer des zones, et de remonter à chaque fois jusqu'aux observations sources. Il tourne d'abord sur un seul serveur MongoDB, puis sur un cluster shardé.

Pour le mettre à l'épreuve, nous lui avons posé une question qui nous tient à cœur. L'un de nous a grandi à Grosse Pointe Woods, près de Détroit, entre 2000 et 2011 : des hivers blancs, des jours d'école annulés pour cause de neige. Aujourd'hui, la neige ne tient plus. Est-ce un souvenir embelli ou un vrai changement ? Et si l'hiver change, change-t-il de la même façon ailleurs ? Nous comparons le Michigan au sud de l'Allemagne : même bande de latitude, deux climats différents, l'un dominé par l'air arctique et la neige d'effet de lac des Grands Lacs, l'autre par l'air atlantique, plus doux.

Notre réponse, développée en section 6 : *l'hiver ne disparaît pas sous forme de neige qui tombe, mais de neige qui reste, et il disparaît le plus vite là où il était déjà le plus proche de zéro.* Pour le montrer, nous suivons le nombre de jours de neige au sol, la quantité de neige tombée et la température des hivers, de 1961 à 2020. Les services de WeatherScope couvrent toute l'année ; l'hiver est le fil rouge de ce rapport.

2 Périmètre Géographique, Temporalité & Provenance des Données

2.1 Périmètre d'étude

Données. Toutes les observations viennent de GHCN-Daily, l'archive quotidienne de la NOAA [1]. Les métadonnées ont été récupérées le 8 novembre 2026 ; l'URL, la date et le SHA-256 de chaque fichier sont dans `data/raw/metadata/MANIFEST.json`. La sélection se refait avec `scripts/select_stations.py`.

Zones. Le Michigan regroupe les stations américaines avec le code d'État `MI`. Le sud de l'Allemagne regroupe les stations situées en Bavière ou en Bade-Wurtemberg, d'après les frontières de Natural Earth [5]. Les deux zones ont une surface proche (environ 146 000 et 106 000 km^2). Nous écartons les stations allemandes au-dessus de 800 m (18 stations, dans les Alpes et la Forêt-Noire), car la neige y dépend surtout de l'altitude ; le Michigan ne dépasse pas 523 m. Les latitudes ne sont pas identiques : la moitié des stations du Michigan sont au sud de 43,0°N, la moitié des allemandes au nord de 48,8°N (figure 1).

Période. Nous étudions 1991–2020, la normale climatique actuelle de l'OMM [2]. La référence pour les anomalies (F3) est 1961–1990 ; elle passe par le même chargement mais est comptée à part. Un hiver va de décembre à février : 30 hivers, de 1990–91 à 2019–20.

Stations. Nous gardons les stations qui ont des données TMAX, TMIN ou PRCP sur 1991–2020 (tableau 1). Les réseaux diffèrent : au Michigan, 675 stations viennent de CoCoRaHS, un réseau de bénévoles [3], et la plupart n'existent que depuis 2005. En Allemagne, le réseau (ECA&D [4]) reste stable. Une moyenne sur toutes les stations montrerait donc surtout l'arrivée de nouvelles stations. Pour les tendances, nous n'utilisons que les 233 stations « à longue série » : celles qui ont au moins 80 % de mois valides sur 1991–2020 pour TMAX, TMIN ou PRCP, un mois étant valide s'il lui manque au plus 5 jours, dont au plus 3 consécutifs (règle 3/5 de l'OMM [2]). L'inventaire de la NOAA en annonçait 269, mais il ne donne que la première et la dernière année et masque les

trous (annexe A). Une fois chargées, les données comptent 5,1 millions de couples station–jour sur 1991–2020 (3,4 millions sur la référence), pour 200 000 demandés.

La hauteur de neige (SNWD) est disponible dans les deux zones. Les chutes de neige (SNOW) n'existent qu'au Michigan.

	Michigan	Sud de l'Allemagne
Stations de la zone	1 560	400
Stations retenues	1 058	295
dont à longue série (mesurée)	94	139
dont débutées en 2005 ou après	763	18
Stations retenues par élément : avec données / sur toute la période		
TMAX	317 / 95	264 / 93
TMIN	319 / 98	264 / 94
PRCP	1 045 / 117	294 / 148
SNOW	1 009 / 109	–
SNWD	890 / 110	287 / 140

Tableau 1: Stations retenues sur 1991–2020 (inventaire NOAA du 8/11/2026).

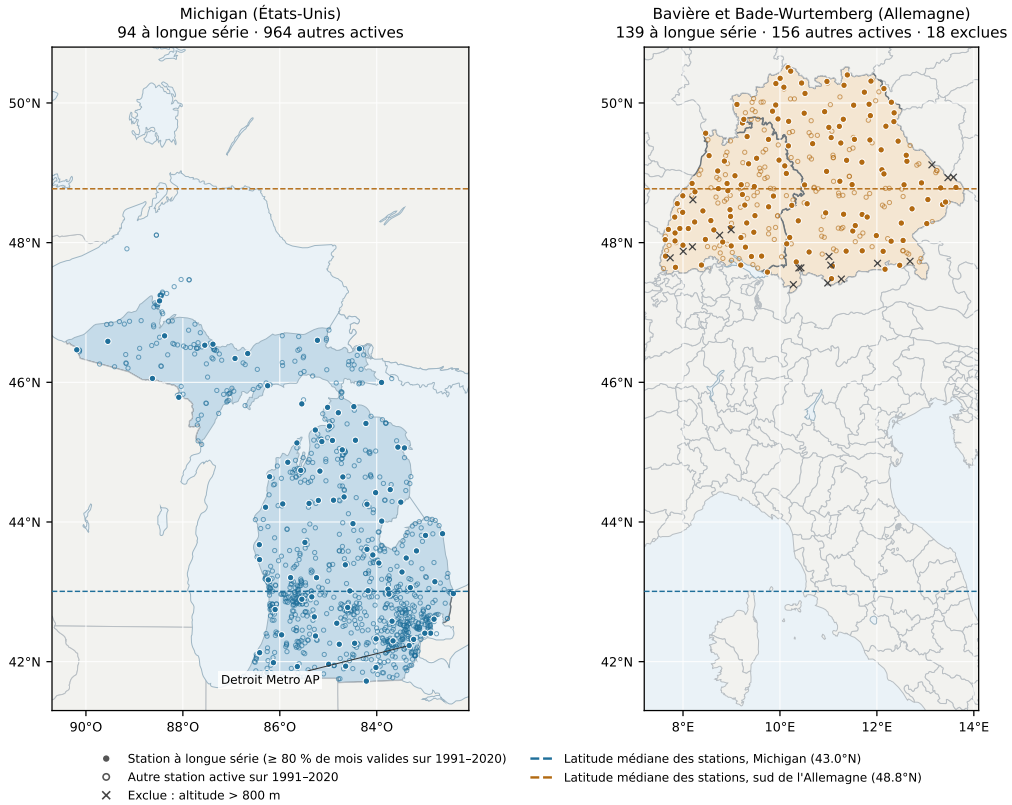


Figure 1: Stations retenues, à la même échelle. Pointillés : latitude médiane des stations de chaque zone.

2.2 Traçabilité, Traitement des Drapeaux (Flags) et Valeurs Manquantes

Traçabilité. Chaque observation garde sa valeur brute, ses trois drapeaux, son heure d'observation, le fichier source et le lot d'import qui l'a écrite. Son identifiant est `station:date:élément` : pour tout résultat, on peut lister les relevés qui l'ont produit. Un import ne crée jamais de doublon : une valeur identique est ignorée, une valeur modifiée remplace l'ancienne, qui est conservée dans un historique. Chaque lot enregistre ses fichiers et leur SHA-256.

Drapeaux. Rien n'est supprimé au chargement ; les règles s'appliquent dans les requêtes. Une valeur avec un drapeau qualité (0,18 % des observations) est exclue des analyses. Le drapeau `P` (« manquant, présumé nul », 1,5 million de valeurs au Michigan) est traité comme une donnée manquante, pas comme un zéro. Une trace (`T`) compte comme un jour de précipitation de quantité négligeable. Les contrôles de la NOAA suffisent : nous n'avons trouvé aucune valeur aberrante ni aucun TMAX inférieur à TMIN sans drapeau (annexe A).

Valeurs manquantes. Nous ne comblons aucun trou. Un mois qui ne respecte pas la règle 3/5 n'entre pas dans les anomalies mensuelles (F3), et un jour manquant ou signalé interrompt un épisode (F2). Deux identifiants à moins d'un kilomètre l'un de l'autre (95 paires) comptent pour un seul site dans F3 et F4.

Heure d'observation. En Allemagne, ECA&D ne donne pas d'heure : chaque valeur couvre le jour climatologique du service météo national. Au Michigan, sur les 315 stations qui mesurent TMAX entre 1991 et 2020, 203 relèvent le matin (surtout à 7 h ou 8 h), 42 l'après-midi ou le soir, 28 à minuit (aéroports) et 42 ne donnent pas d'heure ; 118 ont changé d'heure au moins une fois. Pour une station relevée à 8 h, la TMAX notée le jour J est en général celle de l'après-midi de la veille. Deux stations voisines peuvent donc dater le même épisode avec un jour d'écart. F4 tolère ce décalage d'un jour entre stations, et les deux zones (UTC−5 et UTC+1) sont comparées sur des valeurs mensuelles ou saisonnières, jamais jour par jour.

3 Architecture Système & Implémentation des Services

3.1 Modèle de données

Nous avons choisi MongoDB pour quatre raisons concrètes. Une observation GHCN est un petit document aux champs souvent vides (trois drapeaux, une heure parfois absente), que le modèle document représente tel quel et que `$jsonSchema` valide à l'écriture. Les services sont des agrégations (regroupements par mois, fenêtres glissantes, percentiles) que MongoDB exécute côté serveur. L'index 2dsphere répond aux recherches par zone. Enfin, le sharding est natif : la partie II interroge le cluster par un routeur avec exactement les mêmes requêtes, ce qui est la condition pour obtenir les mêmes réponses.

Les données sont dans MongoDB, avec un document par observation : une station, une date, un élément. L'identifiant `station:date:élément` sert à la fois de clé d'unicité pour les imports (F5) et de référence pour la traçabilité. Quatre collections suffisent : `observations` (34,8 millions de documents après l'import de 2021–2025), `stations` (avec un point GeoJSON), `history` (versions remplacées par un import) et `batches` (un document par import, avec ses fichiers et leurs SHA-256). Des validateurs `$jsonSchema` refusent tout document mal formé ; le détail des champs est dans `schema/README.md`. Trois index couvrent les accès : (station, élément, date) pour une station ;

(zone, élément, date) pour les analyses régionales ; un index 2dsphere sur les stations pour les recherches géographiques.

Conception alternative mesurée. Nous avons comparé ce modèle à un regroupement par mois : un document par station, élément et mois, avec les jours dans un tableau trié. Les deux collections contiennent les mêmes données et donnent des réponses identiques sur les deux requêtes de test (vérifié avant toute mesure). Le tableau 2 résume les mesures (médianes, après une exécution de chauffe, cache de 3 Go).

	Un document par observation	Un document par m
Documents	34,8 M	1,
Sur disque (données / index)	1 054 Mo / 1 846 Mo	306 Mo / 47
R1 : F1 par mois, Détroit, 1961–2020 (7 exécutions)	0,90 s	0,
R2 : F3 mensuel, neige au sol, deux zones, 1961–2020 (3 exécutions)	240,5 s	18

Tableau 2: Comparaison des deux modèles sur les mêmes données (`results/part1/compare_designs.json`).

Le regroupement par mois est 12,7 fois plus rapide sur l'analyse régionale et 3 fois plus petit : ses index tiennent dans le cache, ceux du modèle par observation non. Mais le reste de l'archive est construit autour de l'observation : une révision F5 remplace un document et laisse une trace qui pointe vers un identifiant, `trace` retrouve une ligne NOAA directement, et le validateur contrôle chaque valeur. Dans un tableau de jours, une révision devient la réécriture d'un élément de tableau, plus difficile à rendre idempotente et à auditer. Nous gardons donc les deux, chacun là où il gagne : le modèle par observation reste la source de vérité, et les mois deviennent un modèle de lecture, `obs_months`, que F3 interroge. F5 le tient à jour en reconstruisant, après chaque import, les seuls mois qu'il a touchés (une révision d'une valeur reconstruit un mois). Le coût est modeste : 350 Mo de plus, et une reconstruction limitée aux mois touchés. Le gain : F3 sur les deux zones et 60 ans passe de plus de 2 minutes à 10 secondes.

Cette comparaison a aussi révélé un piège : 9 moyennes mensuelles sur 3 600 différaient à la dernière décimale, parce que des sommes de nombres décimaux ne donnent pas exactement le même résultat selon l'ordre d'addition. Les services additionnent désormais les valeurs brutes entières de la NOAA, exactes dans n'importe quel ordre, et ne convertissent qu'à la fin : c'est ce qui garantit des réponses identiques entre un serveur unique et un cluster.

3.2 Services

Les services sont regroupés dans un outil en ligne de commande, `python3 -m weatherscope`. Leurs entrées, sorties et exemples détaillés sont en annexe B ; nous ne reprenons ici que les choix qui comptent.

F1, explorer une station. Une agrégation par station et par période (mois, année, hiver) donne, à côté de chaque total, la part de jours renseignés et la validité du mois. Un cumul de pluie sur 17 % des jours n'a pas de sens : F1 le dit au lieu de le cacher.

Traçabilité. Tout résultat renvoie à ses relevés : la commande `trace` affiche, pour une station et une période ou une liste d'identifiants, la ligne NOAA d'origine avec ses drapeaux, son fichier et son lot d'import.

F2, épisodes prolongés. MongoDB ne renvoie que les jours qui satisfont la règle et dont la valeur est utilisable ; Python relie les jours consécutifs. Un jour absent ou signalé n'est jamais renvoyé, donc il coupe l'épisode au lieu de le prolonger, et chaque épisode dit pourquoi il s'arrête. Les épisodes suivent la suite des dates, pas l'année civile : la vague de froid du 30 décembre 2013 au 9 janvier 2014 à Détroit reste un seul épisode. La règle peut être un seuil fixe ou un percentile du climat de la station, parce que 30 °C n'a pas le même sens à Munich et à Marquette.

F3, mois anormaux. Chaque mois valide d'une station est comparé à sa normale 1961–1990, la normale précédente, de 30 ans comme le veut la convention [2] et indépendante de la période étudiée ; ses 13,5 millions d'observations sont comptées à part. Une station n'a de normale qu'avec 24 années valides sur 30. Pour que les grappes de stations autour de Détroit ne pèsent pas plus que tout le nord du Michigan, les anomalies sont moyennées par case de 1°, puis les cases entre elles selon leur surface ; deux stations à moins d'un kilomètre comptent pour une. F3 retrouve les mois attendus : mars 2012 au Michigan, août et juin 2003 en Allemagne. Les valeurs mensuelles viennent du modèle de lecture par mois : une requête sur les deux zones et 60 ans prend environ 10 secondes.

F5, mettre à jour l'archive. Une observation est identifiée par sa station, sa date et son élément. À l'import, une observation nouvelle est ajoutée, une observation identique est ignorée, et une observation dont la valeur ou un drapeau a changé remplace l'ancienne, qui part dans l'historique : la NOAA révise son archive en continu, et nous voulons pouvoir montrer ce qui a changé. Nous avons ajouté 2021–2025 depuis les fichiers déjà téléchargés : 3 201 939 observations en 9 minutes, sans rejet. Le même import relancé donne 0 ajout, 3 201 939 inchangées et 0 révision : l'archive reste à 34 830 359 observations, seul le journal des imports enregistre la tentative. Les services calculent tout à la volée et voient donc les nouvelles années aussitôt.

F4, événement régional ou extrême isolé. Chaque jour, F4 compare les cases où au moins une station dépasse le seuil aux cases qui transmettent des données, pondérées par leur surface. Une station muette sort du calcul au lieu de compter comme épargnée. Au-delà de 25 % des cases, le jour est régional ; à deux cases ou plus, local ; à une seule, isolé. Une station peut être décalée d'un jour sur ses voisines, puisque 203 stations du Michigan relèvent le matin la température de la veille : F4 tolère ce décalage. La neige au Michigan en donne les trois visages : le blizzard du 1er au 3 février 2011 touche 57 % des cases, les bandes de neige d'effet de lac du lac Supérieur restent locales ou isolées. Et la neige de juin 1962 en Bavière, sur quatre stations entre 685 et 719 m, sort comme un événement local au pied des Alpes, pas comme une erreur ni comme un épisode régional.

4 Prototype distribué

La partie II garde le modèle et les services de la partie I, mais répartit les deux collections volumineuses, `observations` et `obs_months`, entre plusieurs serveurs MongoDB (*shards*). L'application ne voit qu'un point d'entrée, `mongos`, qui achemine chaque requête vers les shards concernés.

Déploiement. Le script `cluster.py` lance un config server, deux ou trois shards et `mongos`, chacun avec son port et son dossier (annexe D), et ne relance que ce qui est tombé. Chaque shard est un replica set d'un seul membre, comme au lab 5 : MongoDB l'exige, mais aucune copie n'existe. Le cache total est le même que pour le serveur local, 3 Go, réparti entre les shards (1,5 Go chacun avec deux). Ce budget égal ne rend pas les déploiements équivalents : tous les processus partagent

les mêmes cœurs, le même disque et le même cache du système, sans latence réseau ni pannes indépendantes.

Placement. Les deux collections utilisent la même clé, donc les observations d'une station et ses mois sont sur le même shard ; les petites collections restent sur le primary shard. Comme l'identifiant `station:date:élément` contient la station, une observation n'a qu'une destination possible et ne peut pas exister en double sur deux shards. Nous comparons deux politiques. `hashed` hache la station : les données et les écritures sont réparties quelle que soit la zone, F1 touche un shard, mais toute requête par zone est diffusée à tous. `zoned` utilise la clé (zone, station) et place le Michigan sur un shard, l'Allemagne sur l'autre : une requête régionale ne touche que son shard et une panne reste confinée à sa zone, mais l'équilibre dépend du volume de chaque zone, et un troisième shard resterait vide.

Routage. Les services placent la zone dans leurs filtres dès qu'ils connaissent la station, ce qui fixe le préfixe de la clé `zoned`. Le script `route.py` demande à `mongos` le plan de ces filtres (tableau 3). Notre premier découpage en zones s'arrêtait à la dernière station de chaque zone : une requête sur l'Allemagne touchait encore le shard du Michigan. Les zones couvrent maintenant tout l'espace de la clé.

Requête	`hashed`	`zoned`
F1, une station, un an	1	1
F2, sud de l'Allemagne, un été	2 (tous)	1
F3, Michigan, mois 1961–2020 (`obs_months`)	2 (tous)	1
F3, deux zones, mois 1961–2020	2 (tous)	2

Tableau 3: Shards contactés, d'après les plans d'exécution de `mongos` (deux shards).

Mêmes réponses partout. Les sommes portent sur les valeurs brutes entières et les services parcourent leurs résultats dans un ordre fixé : les réponses ne dépendent pas de l'ordre dans lequel les shards répondent. Le script `compare.py` le vérifie automatiquement sur sept requêtes (recherche de stations, F1, F2, F3 sur les mois et sur les observations, F4, `trace`), dont plusieurs touchent les deux shards : les réponses JSON canoniques sont identiques sur les trois déploiements.

Perte d'une instance. Avant d'exécuter un service, `guard()` détermine, à partir des plages de `config.chunks` et sans lire les observations, le shard de chaque station nécessaire, puis teste ces shards. S'il en manque un, le service n'est pas lancé et l'utilisateur reçoit `UNAVAILABLE`, `complete: false`, avec les shards, stations et zones manquants ; une panne en cours de requête donne `ERROR`, jamais un résultat partiel. Si les métadonnées elles-mêmes sont injoignables, la réponse est aussi `UNAVAILABLE`. Avec `shard2RS` arrêté, F1 sur une station allemande et F3 sur les deux zones sont refusées dans les deux profils ; F3 sur le Michigan seul est refusée en `hashed`, où le Michigan est réparti sur les deux shards, mais servie complète en `zoned` (90 mois). Notre prototype ne récupère rien pendant la panne : les données du shard arrêté reviennent à son redémarrage, qui rejoue le journal sans perdre d'écriture acquittée. En production, chaque shard serait un replica set de trois membres, qui élirait un nouveau primaire en quelques secondes ; il faudrait aussi répliquer le config server et multiplier les `mongos`. Un poste unique ne permet de démontrer ni élection, ni partition réseau.

5 Expériences

Machine : un poste Linux (WSL2), 8 cœurs, 7,7 Go de RAM, MongoDB 8.0, cache WiredTiger de 3 Go. Chaque requête est lancée une fois pour chauffer le cache, puis répétée ; nous donnons la médiane (mesures brutes dans `results/`).

E1, volume croissant. Nous avons chargé la période 2011–2020 seule (S1) et l'archive complète 1961–2025 (S3), et lancé sur les deux les mêmes requêtes, toutes situées dans 2011–2020. Faute de temps, le sous-ensemble intermédiaire 1991–2020 n'a pas été mesuré.

	S1 : 2011–2020	S3 : 1961–2025
Observations (dont TMAX, TMIN, PRCP)	6,6 M (4,5 M)	34,8 M (23,2 M)
Chargement F5 / modèle de lecture	517 s / 56 s	4 553 s / 612 s
Données et index (non compressés)	2,4 Go, tient dans le cache	12,6 Go, ne tient pas
F1, Détroit, 10 ans par mois	0,11 s	0,09 s
F2, chaleur, Allemagne, 10 ans	0,90 s	0,84 s
F3, TMAX 2016–2020 contre 2011–2015	2,0 s	1,9 s
F4, fortes neiges, Michigan, 10 ans	4,7 s	5,1 s

Tableau 4: Même requêtes sur deux volumes (`results/e1/e1.json`).

Multiplier l'archive par cinq ne ralentit pas les requêtes : les index (station, élément, date) et (zone, élément, date) ne lisent que la période demandée. C'est le chargement qui souffre : 12 800 observations par seconde tant que tout tient dans le cache, 7 600 en moyenne sur l'archive complète, et moins de 5 000 en fin de chargement.

E2, local contre distribué. Faute de temps, nous n'avons pas chargé l'archive complète dans le cluster pour y chronométrer les requêtes. Nous disposons du chargement des mêmes 31,6 M observations à travers `mongos` (deux shards, profil `hashed`) : 1 280 s, contre 4 009 s sur le serveur local, mais mesuré sur la machine de l'autre membre du groupe, donc sans comparaison directe. Sur un jeu de 14 stations, nous avons vérifié que sept requêtes donnent des réponses identiques sur les trois déploiements et que la perte d'un shard est signalée (section 4).

E3, charge variable. Non réalisée, faute de temps : nous n'avons pas pu déposer de prédiction avant de mesurer.

E4, une limite de notre conception. F4 compte un événement dès qu'une station d'une case dépasse le seuil. Or le réseau du Michigan passe de 170 à 482 stations transmettant des chutes de neige après 2008. Sur toutes les stations, les événements régionaux de fortes neiges (≥ 15 cm) semblent augmenter après 2008 (+6 % par saison) ; sur les 119 stations présentes toute la période (option `--stable-network`), ils diminuent (-17 %). La tendance change de signe : elle venait du réseau, pas du climat. Le réseau stable rend aussi la requête six fois plus rapide (3,8 s contre 22,8 s), au prix d'un maillage plus grossier qui voit moins d'événements locaux (`results/e4/network_bias.json`).

6 Ce que disent les hivers

Notre hypothèse de départ était simple : il neige moins qu'avant. Les données la corrigent. La neige tombe toujours, parfois plus fort ; c'est sa tenue au sol qui recule, et elle recule le plus là où l'hiver

est le plus doux.

Des hivers d'enfance vraiment blancs. La station de Grosse Pointe Farms (`USC00203477`) est à 3,7 km de Grosse Pointe Woods, où l'un de nous a grandi entre 2000 et 2011. Le souvenir d'hivers blancs n'est pas une illusion : ces onze hivers comptent autant de jours de neige au sol que la normale 1961–1990, après une décennie 1990 nettement plus pauvre. C'est après 2011 que tout bascule (tableau 5). À l'aéroport de Détroit, mieux renseigné, la chute est plus modérée, mais la neige tombée, elle, ne baisse presque pas. La figure 2 montre les 59 hivers de cette station.

Moyenne décembre–février	1961–1990	1990–2000	2000–2011	2011–2020
Jours de neige au sol, Grosse Pointe Farms	49	38	48	29
Jours de neige au sol, Detroit Metro	45	31	46	39
Neige tombée, Detroit Metro (mm)	775	745	1 005	965

Tableau 5: Hivers complets (règle 3/5) aux deux stations les plus proches de Grosse Pointe Woods. La station de Grosse Pointe Farms n'a que 5 hivers complets après 2011 : la tendance y est nette, mais repose sur peu d'hivers.

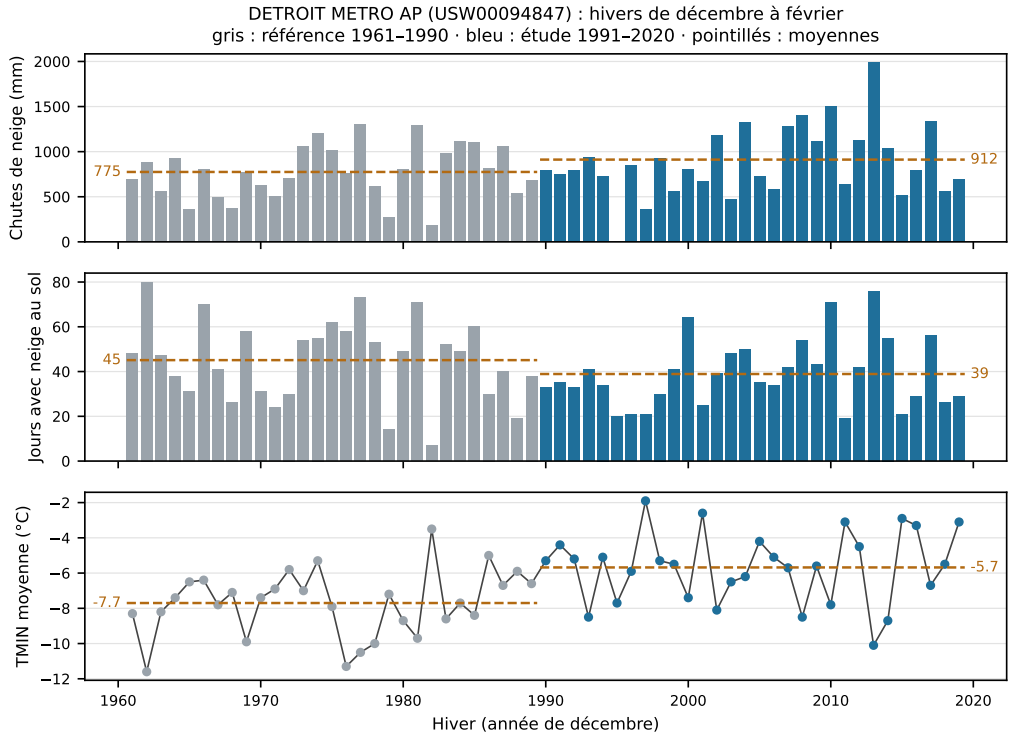


Figure 2: Hivers (décembre–février) à Detroit Metro, calculés par F1. Les hivers qui ne respectent pas la règle 3/5 sont omis.

Et aujourd'hui ? Les hivers 2020–21 à 2024–25, importés après coup par F5, prolongent la courbe. À Detroit Metro, ils comptent 34 jours de neige au sol en moyenne, contre 46 pendant les hivers d'enfance ; 2023–24 n'en a que 16. Et pour la première fois, la neige tombée passe elle aussi sous la normale : 682 mm contre 775. Cinq hivers ne font pas une tendance, mais ils suggèrent la suite : après une neige qui ne tient plus, une neige qui tombe moins.

Autant de neige, mais elle tient moins. Une station ne fait pas une région. Sur les 38 stations du Michigan qui mesurent à la fois la neige tombée et la neige au sol sur les deux périodes, la neige tombée ne bouge pas (1 545 puis 1 554 mm par hiver). Le nombre de jours de neige au sol passe pourtant de 73 à 67, soit 4,75 jours par 10 cm de neige au lieu de 5,28 : une baisse de 10 %, observée à 27 stations sur 38. Les fortes chutes, elles, augmentent : sur 64 stations, F2 compte 11 % de jours de plus de 15 cm par an. L'hiver du Michigan n'est pas moins neigeux, il est moins durable.

Le sud de l'Allemagne perd plus vite. À l'échelle des zones, F3 compare chaque mois d'hiver de 1991–2020 à sa normale 1961–1990. Le Michigan perd 8 % de ses jours de neige au sol (environ 6 jours par hiver) pour un réchauffement de 1,4 °C des minimales. Le sud de l'Allemagne, qui ne se réchauffe que de 1,0 °C, en perd 27 % (environ 12 jours), et la perte s'accélère : -22 % sur 1991–2005, -32 % sur 2006–2020.

Pourquoi : l'hiver allemand a franchi zéro. La réponse tient au point de départ. Sur 66 stations de chaque zone, la journée d'hiver moyenne du Michigan passe de $-5,7$ à $-4,6$ °C : plus chaude, mais encore loin du dégel, avec 63 % des jours sous -2 °C. Celle du sud de l'Allemagne passe de $-0,5$ à $+0,7$ °C : elle a franchi le point de fusion, et la part des jours au-dessus de $+2$ °C est montée de 31 à 40 %. Le même réchauffement fond plus de neige là où l'hiver était déjà au bord du zéro.

Ce qui pourrait nous tromper. L'objection la plus sérieuse est l'arrivée massive de stations bénévoles au Michigan après 2008 : comparer des moyennes sur toutes les stations reviendrait à comparer deux réseaux différents. Tous les chiffres de cette section portent donc sur les mêmes stations aux deux périodes. Nos propres choix de paramètres ne changent pas non plus la conclusion : avec un seuil d'altitude à 600 m, des cases de 0,5° ou de 2°, ou 20 à 27 années exigées pour une normale, le sud de l'Allemagne perd toujours entre 27 et 31 % de ses jours de neige au sol, le Michigan entre 7 et 8 % (annexe C). Garder seulement les stations allemandes sous 600 m, plus proches de zéro, accentue même la perte. Restent deux limites que nous ne levons pas : la façon de mesurer la neige a pu changer d'un observateur à l'autre, et aucun test de significativité n'a encore été fait.

Vérifié sans notre système. Un script séparé (`scripts/verify_independent.py`) relit les fichiers NOAA d'origine avec pandas, sans MongoDB ni notre code, et réapplique les règles à partir de leur définition. Il retrouve les 181 épisodes de chaleur de l'été 2003 que donne F2, identiques station par station et jour par jour, et les 180 mois d'hiver de F3 à 0,005 près, l'écart venant de nos arrondis : $-7,9$ % de jours de neige au sol au Michigan, $-27,0$ % dans le sud de l'Allemagne, comme dans la section 6.

7 Conclusion

WeatherScope charge 34,8 millions d'observations réelles, garde la trace de chacune et répond aux cinq services sur un serveur unique comme sur un cluster, avec les mêmes réponses et sans jamais présenter un résultat partiel comme complet. Le modèle de lecture par mois rend les analyses régionales treize fois plus rapides sans toucher à la source de vérité.

Sur la question qui nous a menés là, la réponse est nette : la neige tombe toujours, mais elle tient moins, et l'hiver recule le plus vite là où il était déjà proche de zéro. Le souvenir d'hivers blancs à Grosse Pointe Woods n'était pas une illusion ; ce qui a changé, c'est la suite.

Les limites sont connues : une seule machine, aucune réplication, E2 incomplète et E3 non réalisée, aucun test statistique sur les tendances. Ce sont les prochaines étapes.

Références

[1] M. J. Menne, I. Durre, R. S. Vose, B. E. Gleason et T. G. Houston. An overview of the Global Historical Climatology Network-Daily database. *Journal of Atmospheric and Oceanic Technology*, 29(7):897–910, 2012.

[2] World Meteorological Organization. *WMO Guidelines on the Calculation of Climate Normals*. WMO-No. 1203, Genève, 2017.

[3] R. Cifelli, N. Doesken, P. Kennedy, L. D. Carey, S. A. Rutledge, C. Gimmestad et T. Depue. The Community Collaborative Rain, Hail, and Snow Network: informal education for scientists and citizens. *Bulletin of the American Meteorological Society*, 86(8):1069–1077, 2005.

[4] A. M. G. Klein Tank et al. Daily dataset of 20th-century surface air temperature and precipitation series for the European Climate Assessment. *International Journal of Climatology*, 22(12):1441–1453, 2002.

[5] Natural Earth. 1:10m Cultural Vectors, Admin 1 – States, Provinces; 1:10m Physical Vectors, Lakes. Version 5.1.2. `https://www.naturalearthdata.com`, domaine public.

A Anomalies relevées dans les données

Les fréquences portent sur les 31,6 millions d'observations chargées (1961–2020, 1 352 stations). Les exemples sont des lignes réelles des fichiers `by_station` de la NOAA, au format `station,date,élément,valeur,M,Q` ; elles ont été relues dans les fichiers d'origine. Comptages produits par `scripts/coverage_report.py` (`results/coverage/anomalies.json`).

A1. Valeurs signalées par un drapeau qualité. 56 360 valeurs (0,18 %) portent un drapeau qualité, dont 47 431 le drapeau `I` (échec d'un contrôle de cohérence interne, par exemple TMAX inférieur à TMIN). Le Michigan en concentre la grande majorité.
`GM000002698,19620128,TMIN,4,,I,E,` (Karlsruhe, 0,4 °C signalé `I`).
Traitement : valeur conservée et traçable, exclue des analyses.

A2. Valeurs physiquement impossibles. 63 valeurs portent le drapeau `X` (hors limites) et 255 le drapeau `G` (valeur aberrante). Le cas le plus net est Big Rapids (Michigan) le 11 janvier 1982 : 2 032 mm de pluie, 2 606 mm de neige et 38,9 °C le même jour d'hiver.

```
USC00200779,19820111,PRCP,20323,,X,0,2400
USC00200779,19820111,SNOW,2606,,X,0,
USC00200779,19820111,TMAX,389,,G,0,2400
```

Nous n'avons trouvé aucune valeur hors de nos bornes de plausibilité sans drapeau NOAA.
Traitement : comme A1.

A3. Précipitations « manquantes, présumées nulles » (drapeau P). 1 466 628 valeurs PRCP ou SNOW portent le drapeau de mesure `P`, sur 298 stations, toutes au Michigan (aucune en Allemagne).
`USC00200032,19820105,PRCP,0,P,,0,2400` (Adrian, Michigan).
Traitement : traitées comme manquantes, jamais comme un vrai zéro. Les traces (`T`, valeur 0) sont comptées comme jour de précipitation de quantité négligeable.

A4. Neige au sol en été, sans drapeau. 4 valeurs de hauteur de neige positives en juin, juillet ou août, toutes les 1er et 2 juin 1962, à quatre stations allemandes différentes (10 à 90 mm).
`GME00102412,19620602,SNWD,40,,,E,` (Kempten, 40 mm).
Traitement : conservées. Plusieurs stations voisines les mêmes jours évoquent plutôt une vraie chute de neige tardive qu'une erreur : c'est le cas qu'un événement régional (F4) doit distinguer d'un extrême isolé.

A5. Un même site sous deux identifiants. 95 paires de stations sont à moins de 1 km l'une de l'autre. À Gelbelsee (Bavière), `GMM00010777` (1988–2003) et `GME00122734` (depuis 1998) sont à 250 m. Sur les 36 jours de 2003 où les deux donnent TMAX, 33 valeurs sont identiques et 3 diffèrent.
`GMM00010777,20030518,TMAX,158,,,S,` `GME00122734,20030518,TMAX,158,,,E,`
`GMM00010777,20030525,TMAX,181,,,S,` `GME00122734,20030525,TMAX,215,,,E,`
Traitement : stations gardées séparément ; dans F3 et F4, une paire ne compte que pour un seul site.

A6. Séries qui commencent, s'arrêtent ou s'interrompent. Au Michigan, 888 stations commencent après janvier 1991 et 609 s'arrêtent avant décembre 2020 (67 et 108 en Allemagne). Parmi les stations à longue série, la plus longue interruption est à Tirschenreuth-Lodermühl : 1 947 jours sans donnée.
`GME00129298,20021031,TMAX,60,,,E,` puis `GME00129298,20080301,TMAX,85,,,E,`
L'inventaire peut masquer ces trous : il annonce TMIN de 1943 à 2026 pour Michigamme (`USC00205403`), alors que le fichier s'arrête en 1949 et ne reprend qu'en 2022.
Traitement : statut « longue série » mesuré mois par mois (règle 3/5 de l'OMM), pas d'après l'inventaire.

B Référence des services

Tous les services s'appellent par `python3 -m weatherscope <commande>` ; chacun accepte `-json` et `-uri` pour viser le serveur unique ou le cluster. Les exemples ci-dessous sont des sorties réelles sur nos données.

B.1 F1 : explorer une station

Entrées. `stations` : une zone (nom, rectangle `-bbox` ou rayon `-near`), éventuellement un élément ou un nom. `f1` : une station, un intervalle de dates, un découpage par mois, année ou hiver, et les éléments voulus.

Sorties. La liste des stations de la zone ; puis, pour chaque élément et chaque période : la disponibilité (jours attendus, jours utilisables, couverture, validité selon la règle 3/5), la qualité (valeurs signalées, drapeaux `P` et `T`) et des statistiques calculées sur les seules valeurs utilisables.

Fonctionnement. Une seule agrégation MongoDB, qui passe par l'index (station, élément, date) et regroupe par élément et par période. Les 30 hivers d'une station s'obtiennent en un peu plus d'une seconde.

Exemple. L'hiver 2013–14 à Detroit Metro (tableau 6) est complet et sans drapeau : 996 mm de neige en janvier et de la neige au sol tous les jours de janvier et de février. À l'inverse, la station bénévole de Woodhaven (`US1MIWY0011`) affiche 683 mm de pluie en 2010, mais avec seulement 17,5 % de jours renseignés : F1 marque l'année comme non valide, et ce total ne doit pas être comparé.

Mois	Couverture	TMIN moy. (°C)	TMIN min (°C)	Neige (mm)	Jours de neige au sol
2013-12	100 %	−6,2	−14,9	396	17
2014-01	100 %	−13,0	−25,5	996	31
2014-02	100 %	−11,1	−20,5	593	28

Tableau 6: Extrait de F1 pour `USW00094847` (Detroit Metro), du 1/12/2013 au 28/2/2014.

B.2 Traçabilité

Entrées. Des identifiants `station:date:élément`, ou une station, une période et des éléments.

Sorties. Chaque relevé tel qu'il est stocké : valeur brute, valeur convertie, drapeaux, heure d'observation, fichier source et lot d'import ; avec `-history`, les versions remplacées par un import ultérieur.

Exemple. Le minimum de −25,5 °C du tableau 6 renvoie à un seul document : valeur brute −255, aucun drapeau, source `W`, relevé à 24 h, fichier `USW00094847.csv.gz`, lot `2026-11-08-initial`. C'est la ligne `USW00094847,20140106,TMIN,-255,,,W,2400` du fichier NOAA.

B.3 F2 : épisodes prolongés

Entrées. Une zone ou une liste de stations, une période, un élément, une durée minimale et une règle : seuil fixe (`-above`, `-below`) ou percentile du climat propre à la station sur 1961–1990 pour le même mois (`-pct-above`, `-pct-below` ; pour la pluie et la neige, calculé sur les jours d'au moins 1 mm). Les stations sans assez de valeurs de référence sont écartées et comptées.

Sorties. Pour chaque épisode : station, début, fin, durée, intensité (écart moyen au seuil), valeur extrême, cumul pour la pluie et la neige, ce qui l'a ouvert et fermé (règle non remplie, jour manquant, jour signalé, limite de la requête) et les paramètres à passer à `trace`.

Exemple. Avec TMAX ≥ 30 °C pendant au moins 5 jours, l'été 2003 donne 181 épisodes sur 160 stations du sud de l'Allemagne ; les plus longs couvrent du 1er au 14 août, avec 40,2 °C à Karlsruhe et à Fribourg (1,5 s). À Détroit, avec TMAX ≤ 0 °C, la vague de froid du 30 décembre 2013 au 9 janvier 2014 sort comme un seul épisode de 11 jours. Au Michigan, sur 1991–2020, 85 épisodes de chaleur se terminent sur un jour manquant et 38 sur un jour signalé ; à `USC00200710`, le 15 août 1995 affiche 32,2 °C avec le drapeau `I` et ne prolonge donc pas l'épisode.

B.4 F3 : mois anormaux

Entrées. Un élément, une ou deux zones, les années étudiées (défaut 1991–2020), la référence (défaut 1961–1990), éventuellement des mois du calendrier (par exemple 12, 1, 2), la taille des cases (défaut 1°), le nombre minimal d'années valides pour une normale (défaut 24) et la part minimale de cases renseignées (défaut 50 %).

Sorties. Pour chaque zone, les mois classés par anomalie standardisée : anomalie, normale, pourcentage de la normale pour la pluie et la neige, nombre de stations et de cases ; pour chaque mois, les stations avec leur valeur, leur normale et leur anomalie, et les dates à tracer. Les mois écartés faute de couverture sont listés.

Exemple. Sur TMAX, les mois en tête sont mars 2012 au Michigan (+8,1 °C, anomalie standardisée 3,5, 76 stations dans 27 cases sur 31) et août puis juin 2003 en Allemagne (+7,0 et +6,9 °C). Une requête sur les deux zones et 60 ans prend environ 10 secondes sur le modèle de lecture par mois, 2 à 4 minutes sur les observations (option `-source observations`), avec des résultats identiques.

B.5 F4 : événements régionaux

Entrées. Une zone, une période, un élément et la même règle que F2 ; la tolérance de décalage entre stations (défaut 1 jour), la taille des cases (défaut 1°), la part de cases touchées pour un jour régional (défaut 25 %) et le nombre minimal de cases (défaut 2).

Sorties. Les événements, chacun classé régional, local ou isolé : début, fin, durée, jour le plus étendu, part et nombre de cases touchées ce jour-là, cases qui transmettent, stations concernées, sévérité (somme sur les jours de la part touchée multipliée par l'écart moyen au seuil), valeur extrême, puis la liste des stations avec leurs dates et les paramètres de `trace`. Les jours voisins d'un événement régional lui sont rattachés.

Exemples. Sud de l'Allemagne, TMAX $\geq$ 30 °C, été 2003 : cinq événements régionaux, dont le plus sévère va du 31 juillet au 29 août et touche les 22 cases (166 stations, 40,2 °C à Karlsruhe et Fribourg), en 1,4 s. Michigan, neige tombée $\geq$ 15 cm, hivers 2010–2015 : 39 événements régionaux (blizzards du 1er–3 février 2011 et du 31 janvier–3 février 2015), 25 locaux et 17 isolés, presque tous dans les ceintures de neige du lac Supérieur, en 6 s. Sud de l'Allemagne, neige au sol fin mai–début juin 1962 : deux événements locaux, dont celui du 31 mai au 3 juin sur 4 des 23 cases (Kempten, Merklingen, Reit im Winkl, Garmisch).

B.6 F5 : mettre à jour l'archive

Entrées. Un nom de lot et des fichiers NOAA (par station ou par année, compressés ou non), ou par défaut les fichiers par station déjà téléchargés ; éventuellement une liste de stations, une période, et l'option `-include-unselected` pour ajouter des stations de nos zones écartées au départ (au-dessus de 800 m).

Sorties. Le bilan du lot : observations ajoutées, inchangées, révisées et rejetées, avec les raisons des rejets ; le lot est enregistré dans `batches` avec ses fichiers et leurs SHA-256, ses mesures dans `results/ingest/`.

Politique. Identité : station, date, élément. Une valeur ou un drapeau différent remplace la valeur stockée, dont l'ancienne version est copiée dans `history` (`trace -history` la montre) ; deux lignes pour la même observation dans un même lot : la seconde est rejetée. Les stations hors de nos deux zones sont ignorées.

Exemples. Import de 2021–2025 : 3 201 939 observations ajoutées sur 744 stations, en 544 s. Même import relancé : 0 ajoutée, 3 201 939 inchangées, 0 révisée, en 707 s. Révision simulée sur une copie modifiée du fichier de Detroit Metro (hauteur de neige du 6 janvier 2014 passée de 410 à 400 mm, drapeau ajouté sur TMIN du 7) : 2 révisions, anciennes versions dans l'historique, ligne en double rejetée.

C Sensibilité aux paramètres

Le résultat central de la section 6 repose sur trois paramètres que nous avons choisis : le seuil d'altitude (800 m), la taille des cases de F3 (1°) et le nombre d'années valides exigé pour une normale (24 sur 30, la règle des 80 % de l'OMM). Le tableau 7 refait le calcul de F3 sur les hivers (décembre à février, 1991–2020 contre 1961–1990) en faisant varier chacun d'eux. Produit par `scripts/sensitivity.py` (`results/sensitivity/winter.json`).

	Jours de neige au sol		TMIN		Stations
Variante	Michigan	Sud de l'All.	Michigan	Sud de l'All.	MI / All.
Référence (800 m, 1°, 24 ans)	$-7,9$ %	$-27,0$ %	$+1,38$ °C	$+0,99$ °C	121 / 136
Altitude $\leq$ 600 m	$-7,9$ %	$-30,8$ %	$+1,38$ °C	$+1,00$ °C	121 / 118
Cases de 0,5°	$-7,6$ %	$-28,2$ %	$+1,37$ °C	$+1,04$ °C	121 / 136
Cases de 2°	$-7,3$ %	$-27,6$ %	$+1,39$ °C	$+0,96$ °C	121 / 136
Normale sur 20 ans	$-7,8$ %	$-26,8$ %	$+1,39$ °C	$+0,97$ °C	128 / 145
Normale sur 27 ans	$-8,4$ %	$-27,2$ %	$+1,35$ °C	$+0,99$ °C	117 / 122

Tableau 7: Évolution des hivers entre 1961–1990 et 1991–2020 selon les paramètres. Le Michigan n'a aucune station au-dessus de 600 m : le seuil d'altitude ne le change pas.

L'écart entre les deux zones tient dans toutes les variantes. Le seul paramètre qui le déplace sensiblement est l'altitude, et dans le sens de notre explication : sans les stations allemandes entre 600 et 800 m, qui ont les hivers les plus froids, la perte de neige au sol passe de 27 à 31 %.

D Déploiement distribué

Processus	Port	Rôle	Dossier	Cache
`mongod` local	27017	serveur de la partie I, référence	`data/db/local`	3 Go
config server	27200	métadonnées : shards, clés, chunks, zones	`cluster_data/config`	0,25 Go
`shard1RS`	27301	données ; primary shard (petites collections)	`cluster_data/shard1`	3/N Go
`shard2RS`	27302	données	`cluster_data/shard2`	3/N Go
`shard3RS`	27303	données (configuration à trois shards)	`cluster_data/shard3`	3/N Go
`mongos`	27400	routeur, seul point d'entrée des profils distribués	–	–

Tableau 8: Processus du déploiement distribué (N shards, $N \in \{2, 3\}$), lancés par `cluster.py`.

Préparation et alimentation. `setup_db.py` active le sharding avec `shard1RS` comme primary shard, crée collections, validateurs et index, puis sharde `observations` et `obs_months` avec la clé du profil ; en `zoned`, il déclare les zones sur tout l'espace de la clé. Les données arrivent soit par F5 à travers `mongos` (`python3 -m weatherscope f5 --profile hashed`), comme pour le serveur local, soit par `sync_from_local.py`, qui recopie les cinq collections de façon idempotente. L'historique (sur

	`hashed`	`zoned`
Clé de shard	`{station: "hashed"}`	`{area: 1, station: 1}`
Placement décidé par	hachage, puis balancer	zones : allocation explicite
Requête sur une zone	diffusée à tous les shards	ciblée sur le shard de la zone
Écritures (F5)	réparties par station	dirigées vers le shard de chaque zone
Équilibre des données	indépendant des zones	dépend du volume de chaque zone
Un shard éteint	toute requête de zone est refusée	seule la zone touchée est refusée
Troisième shard	reçoit des chunks migrés	reste vide

Tableau 9: Les deux politiques de placement.

le primary shard) et l'observation révisée (souvent sur un autre shard) sont écrits sans transaction distribuée : un arrêt entre les deux se rattrape en relançant l'import, au prix d'une entrée d'historique en double.

Limites. Aucune réplication ; un seul `mongos`, un config server d'un membre et un primary shard qui porte `stations`, `history` et `batches` sont autant de points uniques de défaillance ; tous les processus partagent un seul poste.